

# Forecasting with Bayesian Vector Autoregressions

Sune Karlsson

---

## 一、背景：传统的VAR模型

- 由Sims (1980) 提出
- 简单灵活、拟合和预测
- 参数过多→过拟合→系数不符合实际含义、预测效果不好
- 解决方法
  - 用一组数据作为先验减少参数

## 二、主要内容

- 1、贝叶斯方法 ▲预测
- 2、Bayes理论计算及预测
- 3、Minnesota先验分布 etc.
  - 简单模型效果好
- 4、SVAR——a VAR in structural form
- 5、VECM——Vector Error Correction Form of VAR (误差修正模型)
  - 4和5 施加约束条件近似正确时——better
  - 实际预测中应用较少
- 6、条件预测——未来事件
  - 政策分析
- 7、Bayesian VAR models
  - 参数：常数→时变
  - 随机扰动
  - 二者都能提高预测精度，但参数个数急剧增加→过拟合
- 8、VAR
  - 选择变量→减少参数：Bayesian shrinkage等方法

- 9、大数据环境
  - 变量多
  - Bayesian VAR 有竞争力

### 三、模型：

Y对滞后项及其他解释变量回归：

$$Y_{T*m} = Z_{T*k} \Gamma_{k*m} + U_{T*m} \quad U \sim N(0, \Psi)$$

$$k = mp + d : Y(m\text{个变量}, p\text{阶滞后项}) + \text{其他解释变量}(d)$$

$$L(Y|\Gamma, \Psi) = (2\pi)^{-mT/2} |\Psi|^{-T/2} \exp\left\{-\frac{1}{2} \text{tr}[\Psi^{-1}(Y - Z\Gamma)'(Y - Z\Gamma)]\right\}$$

并且假设 $\Gamma$ 服从均匀分布，根据【Jeffreys' prior】有  $\pi(\Gamma, \Psi) \propto |\Psi|^{-(m+1)/2}$

应用贝叶斯公式：  $p(a|b) \propto p(b|a)p(a)$

$$\begin{aligned} p(\Gamma, \Psi|Y_T) &\propto p(Y_T|\Gamma, \Psi)p(\Gamma, \Psi) \\ &\propto |\Psi|^{-T/2} \exp\left\{-\frac{1}{2} \text{tr}[\Psi^{-1}(Y - Z\Gamma)'(Y - Z\Gamma)]\right\} |\Psi|^{-(m+1)/2} \\ &\propto |\Psi|^{-T/2} \exp\left\{-\frac{1}{2} \text{tr}[\Psi^{-1}(Y - Z\hat{\Gamma})'(Y - Z\hat{\Gamma})]\right\} \\ &\quad \times \exp\left\{-\frac{1}{2} \text{tr}[\Psi^{-1}(\Gamma - \hat{\Gamma})'Z'Z(\Gamma - \hat{\Gamma})]\right\} |\Psi|^{-(m+1)/2} \end{aligned}$$

其中应用到OLS估计:  $\hat{\Gamma} = (Z'Z)^{-1}Z'Y$

$$\rightarrow p(\Psi|Y_T) \& p(\Gamma|Y_T, \Psi)$$

对 $Y_{T+H}$ 进行预测时，如果H值较大，写出其分布情况很难，但利用其分布产生随机数就很容易。

---

**Algorithm 1** Simulating the predictive distribution with a normal-Wishart posterior

---

For  $j = 1, \dots, R$

1. Generate  $\Psi^{(j)}$  from the marginal posterior  $\Psi | \mathbf{Y}_T \sim iW_m(\mathbf{S}, T - k)$  distribution using, e.g. the algorithm of Geweke (1988).
2. Generate  $\mathbf{\Gamma}^{(j)}$  from the conditional posterior  $\mathbf{\Gamma} | \mathbf{Y}_T, \Psi^{(j)} \sim N(\hat{\mathbf{\Gamma}}, \Psi^{(j)}, (\mathbf{Z}'\mathbf{Z})^{-1})$
3. Generate  $\mathbf{u}_{T+1}^{(j)}, \dots, \mathbf{u}_{T+H}^{(j)}$  from  $\mathbf{u}_t \sim N(0, \Psi^{(j)})$  and calculate recursively

$$\tilde{\mathbf{y}}_{T+h}^{(j)'} = \sum_{i=1}^{h-1} \tilde{\mathbf{y}}_{T+h-i}^{(j)'} \mathbf{A}_i^{(j)} + \sum_{i=h}^p \mathbf{y}_{T+h-i}' \mathbf{A}_i^{(j)} + \mathbf{x}_{T+h}' \mathbf{C}^{(j)} + \mathbf{u}_{T+h}^{(j)'}. \quad (10)$$

Discarding the parameters yields  $\left\{ \tilde{\mathbf{y}}_{T+1}^{(j)}, \dots, \tilde{\mathbf{y}}_{T+H}^{(j)} \right\}_{j=1}^R$  as a sample of independent draws from the joint predictive distribution.

## 拉普拉斯近似

基本思想是**使用一个高斯分布来近似复杂分布**，求解过程即为求正态分布的期望 $\mu$ 和方差 $\sigma^2$

首先看一下多维变量 $\mathbf{x}$ 的高斯分布公式的形式:

$$\mathcal{N}(\mathbf{x} | \mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right\} \quad (4)$$

其中 $D$ 为 $\mathbf{x}$ 的维度。

假设有一个变量 $\mathbf{z}$  ( $M$ 维向量, 粗体), 其分布为 $p(\mathbf{z})$ , 该分布的具体形式未知, 定义如下:

$$p(\mathbf{z}) = \frac{1}{\mathbf{Z}} f(\mathbf{z})$$
$$\mathbf{Z} = \int f(\mathbf{z}) d\mathbf{z}$$

其中 $\mathbf{Z}$ 为归一化项。

令 $\mathbf{z}_0$ 为 $f(\mathbf{z})$ 的驻点,

$$\ln f(\mathbf{z}) \simeq \ln f(\mathbf{z}_0) - \frac{1}{2}(\mathbf{z} - \mathbf{z}_0)^T \mathbf{A}(\mathbf{z} - \mathbf{z}_0) \quad (5)$$

其中 $\mathbf{A}$ 为 $M \times M$ 的矩阵, 是 $\ln f(\mathbf{z})$ 在驻点 $\mathbf{z}_0$ 处的海森矩阵(Hessian matrix)。

$$\mathbf{A} = \nabla \nabla \ln f(\mathbf{z}) \Big|_{\mathbf{z}=\mathbf{z}_0}$$

对于公式5两边去掉 $\ln$ ，则：

$$f(\mathbf{z}) \simeq f(\mathbf{z}_0) \exp\left\{-\frac{1}{2}(\mathbf{z} - \mathbf{z}_0)^T \mathbf{A}(\mathbf{z} - \mathbf{z}_0)\right\} \quad (6)$$

对比式4中的指数项与式6中的指数项可以发现，如果 $\mathbf{A} = \Sigma^{-1}$ ，则可得归一化的高斯函数 $q(\mathbf{z})$ 为下式：

$$q(\mathbf{z}) = \frac{A^{1/2}}{(2\pi)^{M/2}} \exp\left\{-\frac{1}{2}(\mathbf{z} - \mathbf{z}_0)^T \Sigma^{-1}(\mathbf{z} - \mathbf{z}_0)\right\}$$

其中 $|\mathbf{A}|$ 为矩阵 $\mathbf{A}$ 的行列式。